ДОМАШНЕЕ ЗАДАНИЕ 02

DroPE

Что будет, если убрать RoPE из уже обученной модели?

Разбор статьи и мой эксперимент на двух T4

Extending the Context of Pretrained LLMs by Dropping Their Positional Embeddings

Gelberg, Eguchi, Akiba, Cetin / Sakana AI и Oxford / 2025

11 октября 2026

Почему модель теряется на длинном тексте

При обучении RoPE помогает учитывать, где находятся токены.

01 В привычном контексте это полезная подсказка.

02 За пределами обучающей длины позиционные зависимости меняются. Качество может упасть.

03 Авторы проверяют, можно ли после обучения отказаться от этой подсказки.

Что делают авторы

Они берут готовую модель и меняют её attention.

Шаг	Что меняется
1. Убрать RoPE	Отключить позиционное вращение
2. Нормировать Q и K	Использовать QKNoPE для SmolLM
3. Дать модели адаптироваться	Дообучить на привычных 2048 токенах
4. Проверить длинный контекст	Увеличить длину только при оценке

Причинная маска остаётся. Длинные тексты для адаптации не нужны.

На длинном контексте помогает beta

Больше ключей в attention может размывать распределение вероятности.

$$\text{Attention} = \text{softmax}\left(\beta \cdot QK^T / \sqrt{d} + \text{mask} \right) V$$

Формула авторов для SmolLM

$$\beta(L) = 1 + 0.103 \cdot \ln(\max(1, L / 2048))$$

Я проверил эту формулу и отдельно подобрал beta на dev.

Какие результаты получили авторы

В статье есть обучение с нуля и адаптация готовых моделей.

Эксперимент	Результат статьи
Обучение с нуля, Figure 2	14K шагов RoPE + 2K DroPE дают качество RoPE, обученной 16K шагов
NoPE с нуля	При том же бюджете уступает DroPE
Готовые модели	Адаптация на коротком контексте, затем проверка LM и NIAH на длинном

Мой запуск относится к адаптации готовой SmolLM-360M.

На что хватило двух T4

Сценарий тот же, но объём обучения и настройки заметно отличаются.

Настройка	Статья	Мой запуск
Длина при адаптации	2048	2048
Входные токены	31.46–125.8 млрд	0.3062 млрд
Batch / максимальный LR	512 / 1e−3	8 / 3e−5
Точность / изменение LR	bf16 / cosine	fp16 / постоянный
Текст для NIAH	Paul Graham	FineWeb

Мой бюджет: около 0.97% от самого малого сопоставимого запуска.

Как я обучал и проверял модель

Все версии модели, данных и авторского кода зафиксированы.

Обучение

SmolLM-360M с QKNoPE: сначала 8712 шагов.
После восстановления состояния продолжил до 18689.

Настройки

Две T4, microbatch 1, accum 4, общий batch 8.
Контекст 2048, LR 3e−5, fp16, ZeRO1 и SDPA.

Данные

Dev: 16 блоков по 2048. Test: 8 блоков по 8192.
Для коротких тестов взято начало тех же блоков.

Дообучение помогло на dev

CE снизилась с 3.8254 до 3.4976. Чем меньше, тем лучше.



PPL на dev: 45.85 → 33.04. Один запуск, без повторов с другими seeds.

До исходного качества модель не дошла

В контексте 2048 PPL упала с 612.54 после удаления RoPE до 30.95.

Модель / checkpoint	2048 PPL	4096 PPL	8192 PPL
RoPE без масштабирования	12.64	76.91	286.88
DroPE, шаг 8712	42.66	56.79	85.86
DroPE, шаг 18689	30.95	41.23	81.02

На длинных контекстах beta выбрана по dev. Для 8192 она изменилась с 1.25 на 1.5 между этапами, поэтому эффект обучения отдельно не виден.

Без подбора beta результат гораздо хуже

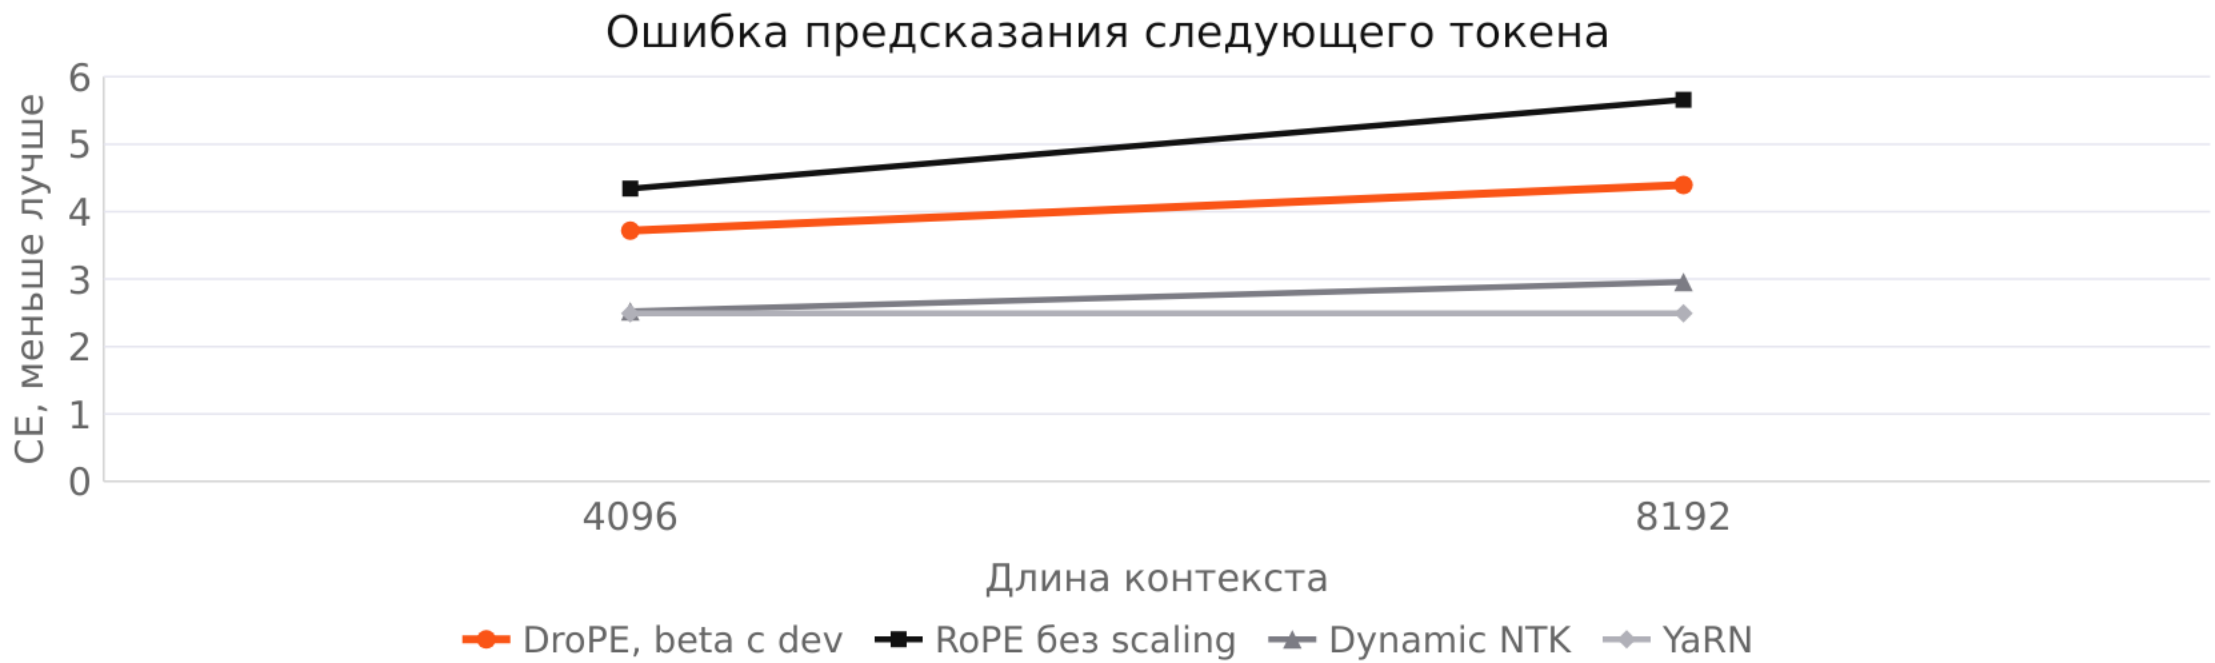
Один финальный checkpoint, разные настройки attention.

Настройка DroPE	4096 PPL	8192 PPL
Без масштабирования	432.66	16 118.88
Beta по формуле статьи	80.94	1387.07
Beta, выбранная на dev	41.23	81.02

Dev выбрал 1.25 для 4096 и 1.5 для 8192. Подбор шёл на двух блоках.
На другом наборе текстов лучшая настройка может измениться.

YaRN и Dynamic NTK оказались лучше

Они применены к исходной RoPE без дообучения. Test-блоки те же.



YaRN/NTK восстановлены из консоли. У YaRN был warning в метаданных.
После правки скрипта повторного GPU-замера не было.

Спрятанное число DroPE не нашёл

Даже в коротком контроле на 512 токенов результат нулевой.

Тест NIAH	RoPE	DroPE
512, глубина .9	10/12 (83.3%)	0/12
2048, глубина .1	3/8 (37.5%)	0/8
2048, глубина .5	4/8 (50.0%)	0/8
2048, глубина .9	8/8 (100%)	0/8
Всего на 2048	15/24 (62.5%)	0/24

Мало примеров, часть текстов и шаблонов повторяется. Counts сохранились в консоли, а исходные ответы дополнительного запуска потеряны.

Что я проверил и чего пока не хватает

Проверки помогают сузить проблему, но не объясняют её целиком.

Исправлен KV-cache

Расхождение logits с кэшем и без него: примерно 1.503 → 0.0173.
Разница CE между SDPA и eager: около 7.3e−5.

Остаются ограничения

Нет RoPE-дообучения на том же числе токенов и повторов по seeds.
Авторский checkpoint через мой evaluator не проверялся.
Публичную ссылку на обученные веса ещё нужно добавить.

Что я могу сказать по результатам

Восстановление качества началось, но его оказалось недостаточно.

01 Языковое качество улучшилось.
Исходную RoPE модель пока не догнала.

02 На длинном LM-тесте помог подбор beta.
YaRN и Dynamic NTK всё равно лучше.

03 Поиск факта в тексте не восстановился.
При таком бюджете это не опровергает статью.